

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA KỸ THUẬT ĐIỆN TỬ 1



BÁO CÁO ĐỀ TÀI

ĐỒ ÁN THIẾT KẾ HỆ THỐNG NHÚNG

ĐỀ TÀI: THIẾT KẾ, CHẾ TẠO QUẠT THÔNG MINH ĐIỀU KHIỂN BẰNG GIỌNG NÓI

Giảng viên : ThS. Lương Công Duẩn

Nhóm học phần : 04

Lớp : D22DTMT02

Nhóm sinh viên :

Nguyễn Đức Cảnh – B22DCDT043

Đỗ Trọng Giáp – B22DCDT099

Hà Nội, 2026

LỜI NÓI ĐẦU

Trong quá trình nghiên cứu chúng em đã nhận được sự giúp đỡ, đóng góp ý kiến và chỉ bảo nhiệt tình của thầy cô, gia đình và bạn bè.

Đầu tiên, em xin được gửi lời cảm ơn đến Ban Giám đốc Học viện Công nghệ Bưu chính Viễn thông đã tạo cho em môi trường rèn luyện tốt để em có thể học tập và tiếp thu được những kiến thức quý báu trong những năm qua.

Em xin cảm ơn tất cả các thầy cô giáo, đặc biệt là các thầy cô trong Khoa Kỹ thuật Điện tử 1 đã tận tình chỉ dạy những kiến thức quý báu để em có thể hoàn thành được đề tài cũng như những hành trang cần thiết để em có thể bước trên con đường sự nghiệp sau này. Em xin được gửi lời cảm ơn sâu sắc nhất đến thầy ThS. Lương Công Duẩn người đã trực tiếp hướng dẫn chúng em thực hiện đề tài này.

Mặc dù công việc rất bận rộn nhưng các thầy cô vẫn luôn dành thời gian hướng dẫn chỉ bảo tận tình để chúng em có thể hoàn thành tốt đề tài.

Mặc dù đã cố gắng hết mình, đề tài không tránh khỏi những thiếu sót. Em rất mong nhận được sự thông cảm và chỉ bảo tận tình của quý thầy cô và các bạn để em có thể hoàn thành tốt hơn báo cáo này.

Cuối cùng em xin kính chúc các thầy cô, gia đình và bạn bè dồi dào sức khỏe và thành công trong sự nghiệp.

Hà Nội, ngày 6 tháng 5 năm 2026

Thành viên	Nhiệm vụ
Nguyễn Đức Cảnh	Thiết kế PCB, training model AI, porting model lên ESP
Đỗ Trọng Giáp	Thu Data để training, Code cấu hình lên ESP, cấu hình ngoại vi TFT, DHT22, DS3231

MỤC LỤC

LỜI NÓI ĐẦU	i
MỤC LỤC	ii
DANH MỤC HÌNH ẢNH.....	iv
CHƯƠNG 1: GIỚI THIỆU CHUNG	5
1.1. Lý do chọn đề tài	5
1.2. Mục tiêu đề tài	5
1.3. Phạm vi đề tài	6
1.4. Phương pháp nghiên cứu	6
1.5. Tổng kết chương 1	7
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	8
2.1. Tổng quan về xử lý dữ liệu âm thanh	8
2.2. Trích xuất đặc trưng Log-Mel Spectrogram	8
2.3. Mô hình mạng nơ-ron tích chập trong nhận diện giọng nói	9
2.4. Mô hình học máy nhúng và phát hiện Wakenet.....	10
2.5. Bộ lọc kết quả AI	11
2.6. Tổng kết chương 2	12
CHƯƠNG 3: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG.....	13
3.1. Sơ đồ khối hệ thống	13
3.2. Thiết kế phần cứng	14
3.3. Thiết kế phần mềm	16
3.3.1. Thiết kế pipeline xử lý.....	16
3.3.2. Thiết kế mô hình nhận diện giọng nói.....	18
3.4. Xây dựng và tích hợp hệ thống.....	19
3.5. Tổng kết chương 3	19
CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ.....	21

4.1.	Môi trường thực nghiệm.....	21
4.2.	Kết quả mô hình huấn luyện.....	21
4.3.	Kết quả nhận diện trên thiết bị.....	23
4.4.	Kết quả bộ lọc AI.....	23
4.5.	Các vấn đề gặp phải và giải pháp	23
4.5.1.	Các vấn đề	23
4.5.2.	Giải pháp	24
4.6.	Đánh giá tổng quát.....	24
TÀI LIỆU THAM KHẢO		26

DANH MỤC HÌNH ẢNH

Hình 1 Quá trình ADC.....	8
Hình 2 Log-Mel Spectrogram	9
Hình 3 Mô hình CNN trong nhận diện giọng nói.....	10
Hình 4 Cơ chế hoạt động của từ khóa WakeNet	11
Hình 5 Mô hình bộ lọc kết quả của AI dự đoán	12
Hình 6 Sơ đồ khối hệ thống.....	13
Hình 7 Sơ đồ mạch nguyên lý	15
Hình 8 2D Bot và Top Layer	15
Hình 9 3D Bot và Top layer.....	15
Hình 10 Pipeline xử lý hệ thống.....	16
Hình 11 Tổ chức các tệp cho mô hình huấn luyện	17
Hình 12 Thông tin tệp âm thanh trong mô hình huấn luyện	17
Hình 13 Ý tưởng thiết kế mô hình nhận diện giọng nói.....	18
Hình 14 Mô hình thiết kế mạng CNN	18
Hình 15 Sơ đồ mô hình huấn luyện CNN	19
Hình 16 Các lớp trong mô hình CNN.....	22
Hình 17 Ma trận nhầm lẫn của stage 1 và stage 2.....	22

CHƯƠNG 1: GIỚI THIỆU CHUNG

1.1. Lý do chọn đề tài

Trong bối cảnh công nghệ IoT và hệ thống nhúng phát triển mạnh mẽ, nhu cầu xây dựng các thiết bị thông minh có khả năng tương tác tự nhiên với con người ngày càng gia tăng. Trong đó, điều khiển bằng giọng nói được xem là một trong những phương thức giao tiếp trực quan và tiện lợi nhất. Tuy nhiên, phần lớn các hệ thống nhận diện giọng nói hiện nay phụ thuộc vào nền tảng điện toán đám mây, dẫn đến các hạn chế như độ trễ cao, yêu cầu kết nối Internet liên tục và tiềm ẩn rủi ro về bảo mật dữ liệu cá nhân.

Xuất phát từ những hạn chế đó, việc nghiên cứu và phát triển một hệ thống nhận diện giọng nói hoạt động hoàn toàn offline trên thiết bị nhúng là cần thiết và có ý nghĩa thực tiễn cao. Đặc biệt, với sự ra đời của các vi điều khiển hiệu năng cao như ESP32-S3, cùng với các thư viện hỗ trợ như esp-sr và TensorFlow Lite Micro, việc triển khai các mô hình trí tuệ nhân tạo trực tiếp trên thiết bị đã trở nên khả thi hơn bao giờ hết.

Bên cạnh đó, trong quá trình nghiên cứu và thực nghiệm, nhận thấy rằng các hệ thống nhận diện giọng nói trên thiết bị nhúng thường gặp phải các vấn đề như sai lệch kết quả, nhiễu môi trường và hạn chế về tài nguyên bộ nhớ. Do đó, đề tài không chỉ dừng lại ở việc xây dựng hệ thống nhận diện mà còn tập trung vào việc cải thiện độ chính xác thông qua các kỹ thuật xử lý tín hiệu và bộ lọc kết quả AI như threshold và margin.

1.2. Mục tiêu đề tài

Mục tiêu của đề tài là xây dựng một hệ thống nhận diện giọng nói hoạt động hoàn toàn offline trên nền tảng vi điều khiển ESP32-S3, đảm bảo khả năng xử lý theo thời gian thực, độ chính xác cao và phù hợp với điều kiện tài nguyên hạn chế của hệ thống nhúng. Hệ thống được thiết kế nhằm cho phép người dùng điều khiển thiết bị thông qua giọng nói một cách tự nhiên, không phụ thuộc vào kết nối Internet.

Cụ thể, đề tài hướng tới việc xây dựng một pipeline xử lý hoàn chỉnh, bao gồm các bước từ thu nhận tín hiệu âm thanh, tiền xử lý, trích xuất đặc trưng đến suy luận bằng mô hình học máy và thực thi lệnh. Trong đó, việc tích hợp thư viện esp-sr để phát

hiện từ khóa kích hoạt đóng vai trò quan trọng trong việc giảm tải cho hệ thống, giúp tối ưu tài nguyên và nâng cao hiệu quả hoạt động.

Bên cạnh đó, đề tài tập trung vào việc phát triển và triển khai mô hình học máy sử dụng TensorFlow Lite Micro, phù hợp với môi trường nhúng. Mô hình cần có khả năng phân loại chính xác các lệnh thoại đã định nghĩa, đồng thời đảm bảo kích thước nhỏ gọn và thời gian suy luận nhanh.

1.3. Phạm vi đề tài

Đề tài tập trung xây dựng một hệ thống nhận diện giọng nói hoạt động hoàn toàn offline trên vi điều khiển ESP32-S3. Nội dung nghiên cứu bao gồm các thành phần chính như thu nhận và xử lý tín hiệu âm thanh, trích xuất đặc trưng Log-Mel Spectrogram, xây dựng và triển khai mô hình học máy bằng TensorFlow Lite Micro, cũng như thiết kế pipeline nhận diện phù hợp với hệ thống nhúng.

Bên cạnh đó, đề tài chú trọng cải thiện độ chính xác thông qua các kỹ thuật lọc kết quả AI như threshold, margin và đánh giá năng lượng tín hiệu sau khi phát hiện từ khóa kích hoạt. Ngoài ra, mô hình phân loại hai giai đoạn cũng được nghiên cứu nhằm nâng cao hiệu năng nhận diện trong điều kiện tài nguyên hạn chế.

Đề tài không bao gồm các nội dung như nhận diện giọng nói liên tục, xử lý ngôn ngữ tự nhiên hoặc triển khai trên nền tảng cloud. Phạm vi nghiên cứu được giới hạn nhằm đảm bảo hệ thống hoạt động hiệu quả trên thiết bị nhúng với yêu cầu thời gian thực.

1.4. Phương pháp nghiên cứu

Đề tài được thực hiện theo phương pháp kết hợp giữa nghiên cứu lý thuyết và thực nghiệm. Trước hết, các kiến thức nền tảng về xử lý tín hiệu số, đặc trưng âm thanh và mô hình học máy được nghiên cứu nhằm xây dựng pipeline nhận diện giọng nói phù hợp với hệ thống nhúng.

Trên cơ sở đó, hệ thống được triển khai thực tế trên vi điều khiển ESP32-S3, bao gồm các bước thu thập dữ liệu, tiền xử lý, trích xuất đặc trưng Log-Mel và huấn luyện mô hình bằng TensorFlow. Mô hình sau khi huấn luyện được chuyển đổi sang TensorFlow Lite Micro để chạy trực tiếp trên thiết bị. Quá trình nghiên cứu được thực hiện theo hướng lặp và tối ưu liên tục. Các kết quả thực nghiệm được sử dụng để đánh

giá và điều chỉnh các thành phần của hệ thống, bao gồm dataset, mô hình và các tham số lọc như threshold, margin và RMS. Qua đó, hệ thống dần được cải thiện về độ chính xác, tốc độ xử lý và tính ổn định trong môi trường thực tế.

1.5. Tổng kết chương 1

Trong chương này, đề tài đã trình bày tổng quan về hệ thống nhận diện giọng nói trên nền tảng nhúng, bao gồm lý do lựa chọn đề tài, mục tiêu, phạm vi và phương pháp nghiên cứu. Qua đó, có thể thấy rằng việc xây dựng một hệ thống nhận diện giọng nói hoạt động offline trên vi điều khiển ESP32-S3 là hướng đi phù hợp với xu thế phát triển của các thiết bị IoT thông minh, đồng thời giải quyết được các hạn chế của các hệ thống phụ thuộc vào cloud.


Chương này cũng đã xác định rõ các nội dung trọng tâm của đề tài, bao gồm xử lý tín hiệu âm thanh, trích xuất đặc trưng, triển khai mô hình học máy bằng TensorFlow Lite Micro và áp dụng các kỹ thuật lọc nhằm nâng cao độ chính xác. Bên cạnh đó, phương pháp nghiên cứu kết hợp giữa lý thuyết và thực nghiệm được lựa chọn nhằm đảm bảo tính khả thi và hiệu quả của hệ thống khi triển khai thực tế.

Những nội dung đã trình bày trong chương này đóng vai trò làm cơ sở định hướng cho các chương tiếp theo, trong đó sẽ đi sâu vào cơ sở lý thuyết, thiết kế hệ thống và đánh giá kết quả thực nghiệm.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về xử lý dữ liệu âm thanh

Tín hiệu âm thanh là tín hiệu tương tự (analog) liên tục theo thời gian, do đó để xử lý trên hệ thống số cần phải trải qua quá trình số hóa. Quá trình này bao gồm hai bước chính là lấy mẫu và lượng tử hóa. Trong đề tài, tín hiệu được lấy mẫu với tần số 16 kHz, đây là mức đủ để tái tạo và phân tích các đặc trưng quan trọng của giọng nói con người.



Hình 1 Quá trình ADC

Sau khi số hóa, tín hiệu được xử lý theo từng đoạn nhỏ thay vì toàn bộ chuỗi liên tục. Phương pháp này cho phép phân tích tín hiệu theo từng khoảng thời gian ngắn, phù hợp với tính chất biến đổi liên tục của giọng nói. Để chuyển tín hiệu từ miền thời gian sang miền tần số, phép biến đổi Fourier ngắn hạn - STFT được sử dụng. Kết quả của STFT là phổ tần theo thời gian, giúp biểu diễn năng lượng của tín hiệu tại các tần số khác nhau.


Ngoài ra, trong quá trình tiền xử lý, các bước như loại bỏ thành phần DC offset, chuẩn hóa biên độ và giảm nhiễu cũng được áp dụng nhằm đảm bảo chất lượng tín hiệu đầu vào cho các bước xử lý tiếp theo.

2.2. Trích xuất đặc trưng Log-Mel Spectrogram

Trong các hệ thống nhận diện giọng nói, việc lựa chọn đặc trưng đầu vào đóng vai trò quyết định đến hiệu năng của mô hình học máy. Một trong những đặc trưng phổ biến và hiệu quả nhất là Log-Mel Spectrogram.

Quá trình trích xuất đặc trưng này bao gồm nhiều bước. Đầu tiên, tín hiệu âm thanh được chia thành các frame nhỏ và áp dụng STFT để thu được phổ tần. Tiếp theo, phổ tần này được chuyển đổi sang thang Mel thông qua bộ lọc Mel filter bank. Thang Mel được xây dựng dựa trên đặc điểm cảm nhận âm thanh của con người, trong đó các tần số thấp được phân giải chi tiết hơn so với tần số cao.

Sau khi áp dụng bộ lọc Mel, giá trị năng lượng của từng dải tần được tính toán và đưa qua hàm logarit nhằm giảm độ biến thiên của dữ liệu. Kết quả cuối cùng là một ma trận hai chiều thể hiện đặc trưng của tín hiệu theo cả thời gian và tần số. Đặc trưng này có kích thước cố định và được sử dụng làm đầu vào cho mô hình học máy.



Hình 2 Log-Mel Spectrogram

2.3. Mô hình mạng nơ-ron tích chập trong nhận diện giọng nói


Trong đề tài, mô hình học máy sử dụng là mạng nơ-ron tích chập (CNN), phù hợp với dữ liệu đầu vào dạng ma trận như Log-Mel Spectrogram. Đặc trưng này có thể xem như một ảnh xám, cho phép CNN khai thác các đặc điểm cục bộ theo thời gian và tần số. Phép tích chập trong CNN được mô tả bởi công thức:

$$y(i, j) = \sum_m \sum_n x(i + m, j + n) \cdot w(m, n) + b$$

Trong đó:

- x : dữ liệu đầu vào (Log-Mel)
- w : kernel (bộ lọc)
- b : bias
- y : đầu ra sau tích chập

Mạng CNN bao gồm các lớp chính như lớp tích chập (Conv), hàm kích hoạt (ReLU), lớp giảm chiều (Pooling) và lớp kết nối đầy đủ (Fully Connected). Các lớp này giúp trích xuất đặc trưng và thực hiện phân loại lệnh thoại.



Hình 3 Mô hình CNN trong nhận diện giọng nói

2.4. Mô hình học máy nhúng và phát hiện Wakenet


Do hệ thống được triển khai trên vi điều khiển có tài nguyên hạn chế, mô hình học máy cần được tối ưu để phù hợp với môi trường này. Trong đề tài, mô hình được triển khai bằng TensorFlow Lite Micro, đây là phiên bản rút gọn của TensorFlow dành cho hệ thống nhúng.

TensorFlow Lite Micro cho phép chạy mô hình trực tiếp trên vi điều khiển mà không cần hệ điều hành phức tạp. Tuy nhiên, để đảm bảo khả năng hoạt động, mô hình cần có kích thước nhỏ, số lượng tham số hạn chế và thời gian suy luận nhanh.

Việc tối ưu mô hình bao gồm các kỹ thuật như giảm số lớp, giảm kích thước đầu vào, hoặc sử dụng các phép toán đơn giản hơn. Điều này giúp mô hình có thể chạy hiệu quả trên vi điều khiển mà vẫn đảm bảo độ chính xác chấp nhận được.

Trong hệ thống nhận diện giọng nói, việc liên tục chạy mô hình AI để xử lý tín hiệu là không hiệu quả và tiêu tốn nhiều tài nguyên. Do đó, một cơ chế phát hiện từ khóa kích hoạt (wake word) được sử dụng để kích hoạt hệ thống khi cần thiết.

Đề tài sử dụng thư viện esp-sr, trong đó tích hợp mô hình WakeNet để phát hiện từ khóa. Khi từ khóa được phát hiện, hệ thống chuyển sang trạng thái lắng nghe lệnh và bắt đầu ghi nhận dữ liệu âm thanh. Cơ chế này giúp giảm tải cho hệ thống, tiết kiệm năng lượng và tăng hiệu quả xử lý.



Hình 4 Cơ chế hoạt động của từ khóa WakeNet


2.5. Bộ lọc kết quả AI

Một trong những thách thức lớn trong nhận diện giọng nói là giảm thiểu sai số do dự đoán không chắc chắn. Để giải quyết vấn đề này, hệ thống áp dụng các kỹ thuật lọc kết quả AI.

Thứ nhất, ngưỡng xác suất (threshold) được sử dụng để đảm bảo rằng chỉ những dự đoán có độ tin cậy cao mới được chấp nhận. Thứ hai, độ chênh lệch giữa hai lớp dự

đoán cao nhất (margin) được tính toán nhằm đánh giá mức độ phân biệt của mô hình. Nếu margin nhỏ, điều đó cho thấy mô hình chưa đủ chắc chắn và kết quả sẽ bị loại bỏ.

Ngoài ra, hệ thống còn sử dụng phương pháp đánh giá năng lượng tín hiệu (RMS) sau khi phát hiện từ khóa. Nếu năng lượng tín hiệu quá thấp, hệ thống sẽ coi đó là nhiễu và bỏ qua, tránh việc nhận diện sai khi không có lệnh thực sự.



Hình 5 Mô hình bộ lọc kết quả của AI dự đoán

2.6. Tổng kết chương 2

Chương này đã trình bày các cơ sở lý thuyết quan trọng phục vụ cho việc xây dựng hệ thống nhận diện giọng nói trên nền tảng nhúng. Các nội dung bao gồm xử lý tín hiệu âm thanh, trích xuất đặc trưng Log-Mel, mô hình mạng nơ-ron, triển khai học máy trên hệ thống nhúng, cũng như các kỹ thuật lọc và tối ưu.


Những kiến thức này là nền tảng để triển khai hệ thống trong chương tiếp theo, nơi sẽ trình bày chi tiết quá trình thiết kế và xây dựng hệ thống thực tế.

CHƯƠNG 3: THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG

3.1. Sơ đồ khối hệ thống

Hệ thống được thiết kế theo mô hình tích hợp giữa phần cứng và phần mềm, trong đó vi điều khiển đóng vai trò trung tâm điều phối toàn bộ hoạt động. Kiến trúc hệ thống được xây dựng theo dạng pipeline, bắt đầu từ thu nhận tín hiệu giọng nói, xử lý dữ liệu, suy luận bằng mô hình học máy và cuối cùng là điều khiển thiết bị đầu ra.

Thiết kế này đảm bảo tính module hóa, giúp hệ thống dễ dàng mở rộng và nâng cấp trong tương lai. Đồng thời, việc phân chia rõ ràng các khối chức năng cũng giúp tối ưu hiệu năng và giảm độ phức tạp trong quá trình triển khai.



Hình 6 Sơ đồ khối hệ thống

- **Khối nguồn:** Khối nguồn bao gồm nguồn điện lưới 220V – 50Hz và module chuyển đổi Hi-Link AC-DC 5V – 3W. Nhiệm vụ của khối này là chuyển đổi điện áp xoay chiều từ lưới điện sang điện áp một chiều 5V ổn định để cung cấp cho toàn bộ hệ thống. Đây là khối quan trọng đảm bảo hệ thống hoạt động ổn định và an toàn.
- **Khối xử lý trung tâm:** Khối xử lý trung tâm sử dụng vi điều khiển ESP32-S3 (N16R8), đóng vai trò là bộ não của hệ thống. ESP32 thực hiện các chức năng chính như:
 - Thu nhận tín hiệu âm thanh từ microphone qua giao tiếp I2S

- Xử lý tín hiệu và trích xuất đặc trưng Log-Mel
 - Thực hiện suy luận bằng mô hình AI (CNN + TFLite Micro)
 - Áp dụng bộ lọc kết quả (threshold, margin, RMS)
 - Điều khiển các thiết bị đầu ra thông qua relay
 - Giao tiếp với các cảm biến và màn hình hiển thị
- Khối thu âm (Microphone INMP441): Microphone INMP441 là cảm biến âm thanh kỹ thuật số sử dụng giao tiếp I2S. Khối này có nhiệm vụ thu nhận tín hiệu giọng nói từ môi trường và truyền trực tiếp về ESP32-S3. Ưu điểm của microphone I2S là giảm nhiễu và đảm bảo chất lượng tín hiệu tốt hơn so với microphone analog.
 - Các ngoại vi khác:

Cảm biến DHT22 được sử dụng để đo nhiệt độ và độ ẩm môi trường. Dữ liệu từ cảm biến được truyền về ESP32 thông qua giao tiếp 1-Wire. Thông tin này có thể được hiển thị trên màn hình hoặc sử dụng cho các chức năng mở rộng của hệ thống.


Module DS3231 cung cấp thông tin thời gian thực với độ chính xác cao. Khối này giao tiếp với ESP32 qua giao thức I2C. Dữ liệu thời gian có thể được sử dụng để hiển thị hoặc phục vụ các chức năng điều khiển theo lịch.

Màn hình TFT được sử dụng để hiển thị thông tin của hệ thống như trạng thái hoạt động, kết quả nhận diện giọng nói, nhiệt độ, độ ẩm và thời gian. Khối này giúp người dùng dễ dàng theo dõi và tương tác với hệ thống.


- Khối đầu ra bao gồm 4 relay trung gian để kích hoạt điều khiển các thiết bị tải điều khiển cần công suất lớn được cấp thông qua tín hiệu từ chân GPIO của vi điều khiển

3.2. Thiết kế phần cứng


Từ sơ đồ khối đã cho thực hiện xây dựng nguyên lý cho thiết bị từ đó bố trí sắp đặt các thiết bị sao cho hợp lý, đảm bảo an toàn kỹ thuật do hệ thống có sử dụng điện lưới 220V – 50Hz. Tính toán phối hợp trở kháng đảm bảo hệ thống chạy ổn định lâu dài không bị sụt áp hoặc bị treo do thiếu nguồn.



Hình 7 Sơ đồ mạch nguyên lý



Hình 8 2D Bot và Top Layer




Hình 9 3D Bot và Top layer

3.3. Thiết kế phần mềm

3.3.1. Thiết kế pipeline xử lý

Hệ thống được xây dựng theo một cấu trúc Pipeline xử lý tuần tự như sau



Hình 10 Pipeline xử lý hệ thống

Trong đó:

- WakeNet: phát hiện từ khóa kích hoạt
- Buffer: lưu tín hiệu âm thanh 2 giây
- Log-Mel: trích xuất đặc trưng
- CNN: phân loại lệnh
- Filter: bộ lọc kết quả
- Execute: thực thi lệnh

Tập dữ liệu được xây dựng nhằm phục vụ cho quá trình huấn luyện và đánh giá mô hình nhận diện giọng nói. Dataset bao gồm các lệnh điều khiển cơ bản của hệ thống như:


- stop
- swing
- turn_off
- turn_on_level_one
- turn_on_level_two
- turn_on_level_three

Dữ liệu giọng nói được thu âm ở tần số lấy mẫu 16 kHz, mono channel và chuẩn hóa về cùng độ dài nhằm đảm bảo tính đồng nhất trong quá trình huấn luyện. Các file âm thanh được lưu dưới định dạng WAV để thuận tiện cho việc xử lý và trích xuất đặc trưng.

Sau khi thu thập, dữ liệu sẽ được chia thành ba tập là “train”, “val” và “test” trong đó train là tập huấn luyện, val là tập kiểm tra và test là tập đánh giá. Việc chia như này sẽ giúp đánh giá khách quan khả năng học và tổng quát hóa của mô hình CNN. Để tăng tính đa dạng của dữ liệu và cải thiện khả năng chống nhiễu, đề tài áp dụng một số kỹ thuật như thay đổi âm lượng; chèn thêm nhiễu nền; dịch chuyển tín hiệu theo thời gian (tốc độ nói nhanh/chậm). Sau quá trình chuẩn bị, dữ liệu được chuyển sang dạng Log-Mel Spectrogram để sử dụng làm đầu vào cho mô hình học máy. Dataset đóng vai trò quan trọng, ảnh hưởng trực tiếp đến độ chính xác và ổn định của hệ thống nhận diện giọng nói.

test	30/04/2026 8:16 CH	File folder
train	30/04/2026 8:16 CH	File folder
val	30/04/2026 8:16 CH	File folder

Hình 11 Tổ chức các tập cho mô hình huấn luyện



Hình 12 Thông tin tệp âm thanh trong mô hình huấn luyện

3.3.2. Thiết kế mô hình nhận diện giọng nói

Mô hình nhận diện giọng nói trong đề tài được xây dựng dựa trên mạng nơ-ron tích chập (CNN) nhằm phân loại các lệnh điều khiển từ tín hiệu âm thanh. Đầu vào của mô hình là đặc trưng Log-Mel Spectrogram được trích xuất từ tín hiệu giọng nói sau khi tiền xử lý.


Dữ liệu đầu vào có kích thước cố định:

$$Input = 249 \times 40 \times 1$$


Trong đó:

- 249: số frame theo thời gian
- 40: số Mel bins
- 1: số kênh dữ liệu


Mô hình CNN được thiết kế theo kiến trúc nhẹ để phù hợp với hệ thống nhúng sử dụng ESP32-S3. Kiến trúc mô hình gồm các lớp tích chập, hàm kích hoạt ReLU, lớp Pooling và lớp Fully Connected.



Hình 13 Ý tưởng thiết kế mô hình nhận diện giọng nói



Hình 14 Mô hình thiết kế mạng CNN



Hình 15 Sơ đồ mô hình huấn luyện CNN

3.4. Xây dựng và tích hợp hệ thống

Sau khi hoàn thành thiết kế phần cứng và phần mềm, hệ thống được tiến hành xây dựng và tích hợp thành một khối hoàn chỉnh. Các thành phần như ESP32-S3, microphone INMP441, màn hình TFT, cảm biến DHT22, RTC DS3231 và relay được kết nối và kiểm tra riêng lẻ trước khi tích hợp toàn hệ thống nhằm đảm bảo hoạt động ổn định.

Phần mềm được phát triển trên nền tảng ESP-IDF với các module chức năng riêng biệt như thu âm, xử lý tín hiệu, nhận diện wake word, suy luận AI và điều khiển thiết bị. Khi hệ thống phát hiện từ khóa kích hoạt bằng ESP-SR, tín hiệu âm thanh sẽ được ghi lại và chuyển sang dạng Log-Mel Spectrogram để đưa vào mô hình CNN.

Mô hình CNN sau khi huấn luyện được chuyển sang định dạng TensorFlow Lite Micro để triển khai trực tiếp trên ESP32-S3. Kết quả suy luận tiếp tục được xử lý qua bộ lọc AI sử dụng threshold, margin và RMS nhằm loại bỏ các dự đoán không chắc chắn hoặc tín hiệu nhiễu.

Sau khi lệnh được xác nhận, ESP32 sẽ điều khiển relay tương ứng để bật hoặc tắt thiết bị, đồng thời cập nhật trạng thái lên màn hình TFT. Quá trình tích hợp được thực hiện nhiều lần nhằm tối ưu độ chính xác, tốc độ phản hồi và tính ổn định của hệ thống trong điều kiện thực tế.

3.5. Tổng kết chương 3

Trong chương này, đề tài đã trình bày quá trình thiết kế và xây dựng hệ thống nhận diện giọng nói trên nền tảng ESP32-S3. Nội dung bao gồm thiết kế phần cứng, xây dựng tập dữ liệu, thiết kế mô hình CNN và quá trình tích hợp các khối chức năng thành một hệ thống hoàn chỉnh.

Bên cạnh đó, chương cũng trình bày pipeline xử lý giọng nói từ bước thu nhận âm thanh, phát hiện từ khóa kích hoạt, trích xuất đặc trưng Log-Mel đến suy luận bằng mô hình học máy và điều khiển thiết bị đầu ra. Các kỹ thuật lọc kết quả AI như threshold, margin và RMS gating đã được tích hợp nhằm nâng cao độ chính xác và giảm thiểu nhận diện sai trong môi trường thực tế.

Kết quả của chương này là xây dựng thành công một hệ thống nhận diện giọng nói hoạt động offline, có khả năng xử lý theo thời gian thực và phù hợp với điều kiện tài nguyên hạn chế của hệ thống nhúng. Đây là cơ sở để tiến hành đánh giá thực nghiệm và phân tích kết quả trong chương tiếp theo.

CHƯƠNG 4: KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Môi trường thực nghiệm

Hệ thống được triển khai trên phần cứng sử dụng vi điều khiển ESP32-S3 kết hợp với microphone INMP441, màn hình TFT và các relay điều khiển thiết bị. Phần mềm được xây dựng trên nền tảng ESP-IDF, trong khi mô hình học máy được huấn luyện bằng TensorFlow và chuyển đổi sang TensorFlow Lite Micro để chạy trực tiếp trên hệ thống nhúng.

Quá trình thực nghiệm được thực hiện trong nhiều điều kiện môi trường khác nhau nhằm đánh giá khả năng hoạt động thực tế của hệ thống. Các thử nghiệm bao gồm môi trường yên tĩnh và môi trường có nhiễu nền nhằm kiểm tra độ ổn định của mô hình cũng như khả năng chống nhiễu của hệ thống nhận diện giọng nói.

4.2. Kết quả mô hình huấn luyện

Sau quá trình huấn luyện, mô hình CNN có khả năng học được các đặc trưng quan trọng của tín hiệu giọng nói và phân loại tương đối chính xác các lớp lệnh. Giá trị loss của mô hình giảm dần theo số epoch, đồng thời độ chính xác trên tập validation tăng ổn định. Điều này cho thấy mô hình có khả năng hội tụ tốt và phù hợp với bài toán nhận diện giọng nói.

Các lớp lệnh được huấn luyện bao gồm:


- stop
- swing
- turn_off
- turn_on_level_one
- turn_on_level_two
- turn_on_level_three

Mặc dù đạt được kết quả khả quan, trong quá trình huấn luyện vẫn xuất hiện hiện tượng mô hình có xu hướng ưu tiên một số lớp nhất định. Điều này chủ yếu xuất phát từ sự mất cân bằng của dataset và sự khác biệt giữa dữ liệu huấn luyện và dữ liệu thực tế.

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 201, 40, 16)	160
batch_normalization (BatchNormalization)	(None, 201, 40, 16)	64
max_pooling2d (MaxPooling2D)	(None, 100, 20, 16)	0
conv2d_1 (Conv2D)	(None, 100, 20, 32)	4,640
batch_normalization_1 (BatchNormalization)	(None, 100, 20, 32)	128
max_pooling2d_1 (MaxPooling2D)	(None, 50, 10, 32)	0
conv2d_2 (Conv2D)	(None, 50, 10, 64)	18,496
batch_normalization_2 (BatchNormalization)	(None, 50, 10, 64)	256
max_pooling2d_2 (MaxPooling2D)	(None, 25, 5, 64)	0
global_average_pooling2d (GlobalAveragePooling2D)	(None, 64)	0
dense (Dense)	(None, 64)	4,160
dropout (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 4)	260

Total params: 28,164 (110.02 KB)
Trainable params: 27,940 (109.14 KB)
Non-trainable params: 224 (896.00 B)

Hình 16 Các lớp trong mô hình CNN



Hình 17 Ma trận nhầm lẫn của stage 1 và stage 2

4.3. Kết quả nhận diện trên thiết bị

Sau khi triển khai mô hình trên ESP32-S3, hệ thống có khả năng nhận diện giọng nói và thực hiện điều khiển theo thời gian thực. Khi người dùng phát âm từ khóa kích hoạt, hệ thống chuyển sang trạng thái lắng nghe, ghi lại đoạn âm thanh và thực hiện suy luận bằng mô hình CNN.

Kết quả thực nghiệm cho thấy hệ thống có thể nhận diện chính xác các lệnh cơ bản với thời gian phản hồi tương đối nhanh. Các lệnh sau khi được xác nhận sẽ điều khiển relay tương ứng để bật hoặc tắt thiết bị. Đồng thời, trạng thái nhận diện được hiển thị lên màn hình TFT giúp người dùng dễ dàng theo dõi hoạt động của hệ thống.

4.4. Kết quả bộ lọc AI

Trong quá trình thử nghiệm, bộ lọc AI đóng vai trò quan trọng trong việc giảm các trường hợp nhận diện sai. Sau khi mô hình CNN đưa ra kết quả dự đoán, hệ thống tiếp tục đánh giá thông qua các tham số như threshold, margin và RMS gating trước khi quyết định chấp nhận lệnh.

Việc áp dụng bộ lọc giúp loại bỏ đáng kể các trường hợp nhiễu hoặc các dự đoán không chắc chắn. Đặc biệt, trong môi trường có tạp âm hoặc khi người dùng phát âm không rõ, hệ thống vẫn duy trì được độ ổn định tương đối tốt. Ngoài ra, RMS gating còn giúp hạn chế hiện tượng wake word được kích hoạt nhưng không có lệnh thực tế.

4.5. Các vấn đề gặp phải và giải pháp

4.5.1. Các vấn đề

Trong quá trình triển khai thực tế, hệ thống gặp một số khó khăn liên quan đến tài nguyên phần cứng và chất lượng dữ liệu. Một trong những vấn đề chính là hiện tượng bias mô hình, khi hệ thống có xu hướng nhận diện nhiều hơn ở một số lớp lệnh nhất định. Nguyên nhân chủ yếu xuất phát từ dataset chưa thực sự cân bằng và số lượng dữ liệu huấn luyện còn hạn chế.

Bên cạnh đó, sự khác biệt giữa môi trường huấn luyện và môi trường triển khai thực tế cũng ảnh hưởng đáng kể đến kết quả nhận diện. Nhiều môi trường, khoảng cách microphone và cách phát âm khác nhau làm giảm độ chính xác của mô hình. Ngoài ra, giới hạn RAM và bộ nhớ Flash của ESP32-S3 cũng gây khó khăn trong việc triển khai các mô hình có kích thước lớn.

4.5.2. Giải pháp

Để khắc phục các vấn đề trên, đề tài đã áp dụng nhiều giải pháp tối ưu khác nhau. Trước hết, dataset được cân bằng lại và bổ sung thêm các dữ liệu nhiễu nhằm tăng khả năng tổng quát hóa của mô hình. Các bước preprocessing cũng được chuẩn hóa giữa môi trường huấn luyện và triển khai để giảm sai lệch đầu vào.

Ngoài ra, các tham số threshold và margin được điều chỉnh nhiều lần nhằm tìm ra mức phù hợp nhất cho hệ thống. RMS gating cũng được bổ sung để loại bỏ các tín hiệu yếu hoặc nhiễu sau khi kích hoạt wake word. Bên cạnh đó, mô hình CNN được tối ưu theo hướng nhẹ hơn để giảm sử dụng bộ nhớ nhưng vẫn đảm bảo độ chính xác cần thiết.

4.6. Đánh giá tổng quát

Kết quả thực nghiệm cho thấy hệ thống có khả năng nhận diện giọng nói offline với độ trễ thấp và khả năng hoạt động ổn định trên nền tảng nhúng. Việc kết hợp giữa mô hình CNN và các kỹ thuật lọc AI giúp nâng cao đáng kể độ chính xác của hệ thống trong điều kiện thực tế.

Mặc dù vẫn còn một số hạn chế liên quan đến dataset và tài nguyên phần cứng, hệ thống nhìn chung đã đáp ứng được các mục tiêu đặt ra ban đầu. Đây là nền tảng quan trọng để mở rộng và phát triển các ứng dụng điều khiển thông minh bằng giọng nói trong tương lai.




BÁO CÁO KIỂM TRA TRÙNG LẶP

Thông tin tài liệu

Tên tài liệu:	TTCS
Tác giả:	B22DCDT043_Nguyễn Đức Cảnh
Điểm trùng lặp:	17
Thời gian tải lên:	22:38 06/05/2026
Thời gian sinh báo cáo:	01:00 07/05/2026
Các trang kiểm tra:	26/26 trang



Kết quả kiểm tra trùng lặp



Nguồn trùng lặp tiêu biểu

123docz.net tailieu.vn www.slideshare.net

TÀI LIỆU THAM KHẢO

- [1] N. Minh, Hệ thống nhúng, Hà Nội: Nhà xuất bản Thông tin và Truyền thông, 2010.
- [2] E. J. R. Van Hiep Phung, “A High-Accuracy Model Average Ensemble of Convolutional Neural Networks for Classification of Cloud Image Patches on Small Datasets,” 23 Oct 2019.
- [3] K. D. N, “A High-Accuracy Model Average Ensemble of Convolutional Neural Networks for Classification of Cloud Image Patches on Small Datasets,” 6 Jun 2018.
- [4] Feng Ye; Jun Yang, “A Deep Neural Network Model for Speaker Identification,” 16 Apr 2021.